






PUCP



DEPARTAMENTO ECONOMÍA
FUNDAMENTOS DE ECONOMETRÍA
1ECO11 – HORARIO 0723

Sesión 2

El Modelo de Regresión Lineal Bivariado

Docente: Juan Palomino



Índice

1

Análisis de Regresión

2

La Muestra de Observaciones

3

Supuestos del Modelo Clásico

4


La Función de Regresión Muestral

5


Estimación por Mínimos Cuadrados Ordinarios

1. Análisis de Regresión

Relaciones empíricas



a) Una relación determinística



b) Una relación estadística

Figura 1. Relaciones determinísticas y estadísticas

Objetivo: explicar y pronosticar el comportamiento de la variable dependiente “Y” a través del comportamiento de la o las variables independientes “X”.

Finalidad:

- Analiza relaciones de causalidad entre las variables económicas
- Realizar pronósticos o proyecciones del comportamiento de una variable

Función de Regresión Poblacional

Se le llama “regresión” o **Función de Regresión Poblacional (FRP)** a la expresión:

$$Y_i = \beta_1 + \beta_2 X_i$$

Esta expresión lineal resume la verdadera relación existente entre la variable X e Y .

El modelo a estimar es:

$$Y_i = \beta_1 + \beta_2 X_i + \varepsilon_i$$

Donde:

- Y es la variable dependiente o explicada
- X es la variable independiente o explicativa
- ε es la perturbación aleatoria

Esta expresión deja en claro que la relación X e Y no es exacta, debido a ε .

2. La Muestra de Observaciones

La Muestra de Observaciones

1. Notación de los datos:

- **Datos de Corte Transversal:** Y_i, X_i donde $i = 1, 2, \dots, n$
- **Datos de Series de Tiempo:** Y_t, X_t donde $t = 1, 2, \dots, T$
- **Datos de Panel:** Y_{it}, X_{it} donde $i = 1, 2, \dots, n$ y $t = 1, 2, \dots, T$

2. Importancia de la aleatoriedad de la muestra.

¿A qué problema puede conllevar una muestra no aleatoria?

La Muestra de Observaciones

Figura 2. Problema de Muestreo



3. Supuestos del Modelo Clásico

Supuestos del Modelo Clásico: Linealidad

Supuesto 1: Linealidad

La relación entre la variable dependiente Y y la variable independiente X es lineal. El modelo a estimar es:

$$Y_i = \beta_1 + \beta_2 X_i + \varepsilon_i \quad i = 1, \dots, n$$

Donde β_1 y β_2 son parámetros poblacionales desconocidos a ser estimados, y ε_i son términos de errores observados.

Supuestos del Modelo Clásico: Linealidad

Es importante entender que significa β_1 y β_2 :

- β_1 : intercepto, el cual multiplica al número 1 (la constante)
- β_2 : es el efecto marginal o la pendiente o el impacto de X sobre Y , $\frac{\partial Y}{\partial X}$

Preguntas:

Las siguientes especificaciones cumplen con la propiedad de Linealidad:

$$Y_i = \beta_1 + \beta_2 X_i^2 + \varepsilon_i \quad \rightarrow \quad \text{Es lineal}$$

$$Y_i = e^{\beta_1} X_i^{\beta_2} + \varepsilon_i \quad \rightarrow \quad \text{No es lineal}$$

Nota: La propiedad de linealidad es una propiedad de los parámetros, no de las variables.

Supuestos del Modelo Clásico: Linealidad

Ejemplo: Retornos a la Escolaridad

Ecuación de Mincer: ¿Cuál es el impacto de los años de educación sobre los salarios?

$$\log(w_i) = \beta_1 + \beta_2 sch_i + \varepsilon_i$$


- β_2 mide el cambio proporcional en salarios asociado con el incremento de un año de escolaridad

$$\beta_2 = \frac{\partial \log w_i}{\partial sch_i} = \frac{1}{w_i} \frac{\partial w_i}{\partial sch_i} = \frac{\frac{\partial w_i}{w_i}}{\frac{\partial sch_i}{sch_i}} = \frac{\text{cambio relativo en } w_i}{\text{cambio absoluto en } sch_i}$$

- Notar que $\% \Delta w = 100 \cdot \beta_2 \cdot \Delta sch$, es decir, si aumenta un año de escolaridad, se espera que el salario cambie en $100 \cdot \beta_2$ por ciento.

Supuestos del Modelo Clásico: Linealidad

Figura 3. Relación Lineal entre los años de educación y el salario



Supuestos del Modelo Clásico: Exogeneidad Estricta

Supuesto 2: Exogeneidad Estricta

El valor esperado de la perturbación aleatoria debe ser cero para cualquier observación:

$$E[\varepsilon_i|X_i] = 0 \quad i = 1, 2, \dots, n$$


Dados diferentes valores de X en la población, el promedio no observable es igual a cero.

Esto también se puede escribir como:

$$E[\varepsilon|X = X_i] = 0$$


Supuestos del Modelo Clásico: Exogeneidad Estricta

Figura 4. Recta de regresión poblacional y el término de perturbación



Supuestos del Modelo Clásico: Exogeneidad Estricta

Figura 5. Caso donde no se cumple el supuesto



Supuestos del Modelo Clásico: Exogeneidad Estricta

Consecuencias de Exogeneidad Estricta:

Definición: Ley de Esperanzas Iteradas

Si $E|Y| < \infty$, es decir, la esperanza poblacional de Y existe, entonces para cualquier vector X aleatorio:

$$E_X[E(Y|X)] = E(Y)$$

1. Media Incondicional

La media incondicional del término de error es cero:

$$E(\varepsilon_i) = 0$$

Demostración. Por la Ley de Esperanzas Iteradas (LIE)

$$E(\varepsilon_i) = E[E(\varepsilon_i|X)] = 0$$

Supuestos del Modelo Clásico: Exogeneidad Estricta

Consecuencias de Exogeneidad Estricta:

2. Regresores son ortogonales al término de error

Si $E(xy)$ de dos variables aleatorias x e y es cero, entonces decimos que x es ortogonal a y . Bajo exogeneidad estricta, el regresor X es ortogonal al término de error ε para todas las observaciones, es decir, no comparten información.

$$E(X_i \varepsilon_i) = 0 \quad i = 1, 2, \dots, n$$

Supuestos del Modelo Clásico: Exogeneidad Estricta

Consecuencias de Exogeneidad Estricta:

3. Condición de cero correlación

El regresor no está correlacionado con el término de error:

$$\text{Cov}(\varepsilon_i, X_i) = 0$$



Demostración:

$$E(\varepsilon_i X_i) - E(X_i)E(\varepsilon_i) = 0$$

Donde:

$$E(\varepsilon_i X_i) = 0$$

$$E(\varepsilon_i) = 0$$

4. Media condicional de y_i

La media condicional de la variable dependiente es una función lineal del regresor.

Bajo el supuesto de linealidad y exogeneidad estricta:

$$E(Y_i|X_i) = E(\beta_1 + \beta_2 X_i + \varepsilon_i|X_i) = \beta_1 + \beta_2 X_i + E(\varepsilon_i|X_i)$$

$$E(Y_i|X_i) = \beta_1 + \beta_2 X_i$$

Supuestos del Modelo Clásico: Perturbaciones Esféricas

Supuesto 3: Perturbaciones Esféricas

❖ Homocedasticidad

Asume que todas las unidades tienen el mismo error de varianza

$$\text{Var}[\varepsilon_i | X_i] = \sigma^2 > 0 \quad i = 1, 2, \dots, n$$

❖ No Correlación

Asume también que no hay correlación entre las observaciones

$$\text{Cov}[\varepsilon_i \varepsilon_j | X_i X_j] = 0 \quad i, j = 1, 2, \dots, n \quad i \neq j$$

Supuestos del Modelo Clásico: Perturbaciones Esféricas

Este supuesto señala que la varianza de todos los términos de errores es constante. Para ver esto:

$$Var[\varepsilon_i|X_i] = E(\varepsilon_i^2|X) - [E(\varepsilon_i|X)]^2 \quad (\text{Por varianza condicional})$$

$$Var[\varepsilon_i|X_i] = E(\varepsilon_i^2|X) \quad (\text{Por exogeneidad estricta})$$

Similarmente, la covarianza de la distribución conjunta de $\varepsilon_i\varepsilon_j$ condicional a X es cero.


$$Cov[\varepsilon_i\varepsilon_j|X_iX_j] = 0 \quad i, j = 1, 2, \dots, n \quad i \neq j$$

$$E[\varepsilon_i\varepsilon_j|X_iX_j] - E(\varepsilon_i|X_i)E(\varepsilon_j|X_j) =$$

$$E[\varepsilon_i\varepsilon_j|X_iX_j] = 0$$

Supuestos del Modelo Clásico: Perturbaciones Esféricas

Figura 6. Homocedasticidad



Supuestos del Modelo Clásico: Regresores no estocásticos

Supuesto 4: Regresores no estocásticos

Las observaciones de X_i son fijos en muestras repetidas.

Asumir que los X son fijos quiere decir que, en repetidas muestras de X , los valores obtenidos X_1, X_2, \dots, X van a ser siempre los mismos; es decir, dejan de ser aleatorios.

Bajo este supuesto, ya no es necesario hablar de esperanzas condicionales:

$$E(\varepsilon_i) = 0$$

$$\text{Var}(\varepsilon_i) = \sigma^2$$

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$$

Supuestos del Modelo Clásico: Normalidad de los errores

Supuesto 5: Normalidad de los errores

ε_i distribuye normal con media cero y varianza σ^2 condicional a X :

$$\varepsilon_i|X \sim N(0, \sigma^2), \quad i = 1, 2, \dots, n$$

4. La Función de Regresión Muestral

La Función de Regresión Muestral

Objetivo: encontrar una aproximación a la Función de Regresión Poblacional (FRP) a partir de la muestra de observaciones.

La Función de Regresión Muestral (FRM) se define como:


$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i$$

Donde:

- \hat{Y}_i es un estimador de $E(Y_i|X_i)$
- $\hat{\beta}_1$ es un estimador del parámetro poblacional β_1
- $\hat{\beta}_2$ es un estimador del parámetro poblacional β_2

La Función de Regresión Muestral

Figura 7. Rectas de Regresión Poblacional y Muestral



La Función de Regresión Muestral

En esta Figura se muestran las distancias entre dos puntos de observaciones y lo estimado por la recta.

Esta distancia son los residuos definidos:

$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i = Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i$$

Se puede escribir así también:

$$Y_i = \hat{\beta}_1 + \hat{\beta}_2 X_i + \hat{\varepsilon}_i$$

Este se denomina como **modelo estimado**.

La Función de Regresión Muestral

Tenemos dos grupos de ecuaciones: las poblacionales y las muestrales.

- Modelo Econométrico:

$$Y_i = \beta_1 + \beta_2 X_i + \varepsilon_i$$

- Función de Regresión Poblacional

$$E(Y_i|X_i) = \beta_1 + \beta_2 X_i$$

- Modelo Estimado:

$$Y_i = \hat{\beta}_1 + \hat{\beta}_2 X_i + \hat{\varepsilon}_i$$

- Recta estimada o Función de Regresión Muestral:

$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i$$

5. Estimación por Mínimos Cuadrados Ordinarios

Estimación por MCO

Existen métodos para calcular la Función de Regresión Muestral, siendo el más usado el método de Mínimos Cuadrados Ordinarios (MCO)

La recta que mejor se ajuste a los datos será aquella que presente la menor suma de cuadrados de los residuos.

Para ello, se define a la sumatoria de cuadrados de los residuos (SCR) como:

$$SCR = \sum_i^n \hat{\varepsilon}_i^2 = \sum_i^n (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i)^2$$

Objetivo: Hallar $\hat{\beta}_1$ y $\hat{\beta}_2$ de manera que minimice la SCR .

Estimación por MCO

$$SCR = \sum_{i=1}^n \hat{\varepsilon}_i^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i)^2$$

Entonces, obtenemos las denominadas “ecuaciones normales” de la estimación MCO:

$$\frac{\partial SSR}{\partial \hat{\beta}_1} = -2 \sum_{i=1}^n (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i) = 0$$

$$\frac{\partial SSR}{\partial \hat{\beta}_2} = -2 \sum_{i=1}^n (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i) \cdot X_i = 0$$

Estimación por MCO

Entonces, se cumple que:

$$\sum_{i=1}^n (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i) = 0$$

Desarrollando el paréntesis:

$$\sum_{i=1}^n Y_i = n\hat{\beta}_1 + \hat{\beta}_2 \sum_{i=1}^n X_i = 0$$

Dividiendo ambos lados por n , se obtiene:

$$\bar{Y} = \hat{\beta}_1 + \hat{\beta}_2 \bar{X}$$

Despejamos el valor de $\hat{\beta}_1$ y obtenemos:

$$\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X}$$

Estimación por MCO

De la ecuación de $\frac{\partial SSR}{\partial \hat{\beta}_2}$:

$$\sum_{i=1}^n (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i) \cdot X_i = 0$$

Desarrollando el paréntesis:

$$\sum_{i=1}^n Y_i X_i = \hat{\beta}_1 \sum_{i=1}^n X_i + \hat{\beta}_2 \sum_{i=1}^n X_i^2 = 0$$

Estimación por MCO

Reemplazando $\hat{\beta}_1$:

$$\sum_{i=1}^n Y_i X_i = (\bar{Y} - \hat{\beta}_2 \bar{X}) \sum_{i=1}^n X_i + \hat{\beta}_2 \sum_{i=1}^n X_i^2 = 0$$

$$\sum_{i=1}^n Y_i X_i - \bar{Y} \sum_{i=1}^n X_i = \hat{\beta}_2 \left(\sum_{i=1}^n X_i^2 + \bar{X} \sum_{i=1}^n X_i \right)$$

$$\hat{\beta}_2 = \frac{\sum_{i=1}^n Y_i X_i - \bar{Y} \sum_{i=1}^n X_i}{\sum_{i=1}^n X_i^2 + \bar{X} \sum_{i=1}^n X_i}$$

Esta expresión es igual a:

$$\hat{\beta}_2 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

De aquí se obtiene $\hat{\beta}_1$

Referencias

Capítulo 2 y 3 - Gujarati, D., & Porter, D. (2010). *Econometría* (Quinta edición ed.). & P. Carril Villareal, Trad.) México: Mc Graw Hill educación.

Capítulo 2 y 3 - Wooldridge, J. M. (2006). *Introducción a la econometría. Un enfoque moderno: un enfoque moderno*. Editorial Paraninfo.



PUCP